


**LAPORAN AKHIR
TUGAS DSAI**

**SISTEM VOICE EXTRACTION UNTUK INVENTORI IKAN DI
MAKASSAR BERBASIS WHISPER FINE-TUNED**

***VOICE EXTRACTION SYSTEM FOR FISH INVENTORY IN MAKASSAR
BASED ON FINE-TUNED WHISPER***



Azhar Maulana
24/533487/PA/22582

**PROGRAM STUDI ILMU KOMPUTER
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**

2026

DAFTAR ISI

DAFTAR ISI		ii
1	Latar Belakang	1
2	Rumusan Masalah	1
3	Tujuan Proyek	2
4	Batasan Masalah	2
5	Metodologi	2
5.1	Pengumpulan dan Persiapan Dataset	2
5.2	Arsitektur Model	4
5.3	Pipeline AI	4
5.4	Proses Fine-Tuning	5
5.5	Deployment	6
6	Hasil dan Evaluasi	7
6.1	Hasil Training	7
6.2	Hasil Evaluasi Model	7
6.3	Hasil Inferensi	7
6.4	Hasil Deployment	8
6.5	Kelebihan dan Keterbatasan Sistem	8
7	Kesimpulan dan Saran	9
7.1	Kesimpulan	9
7.2	Saran	9

1 Latar Belakang

Industri perikanan di Makassar merupakan salah satu sektor ekonomi utama yang melibatkan ribuan nelayan dan pedagang ikan setiap harinya. Proses pencatatan inventori ikan di pelabuhan maupun pasar ikan masih dilakukan secara manual, yang rentan terhadap kesalahan pencatatan, lambat, dan tidak efisien. Nelayan dan pedagang ikan umumnya terbiasa menyampaikan informasi secara lisan, seperti jenis ikan, *grade* kualitas, dan jumlah kilogram, sehingga pendekatan berbasis suara dinilai lebih natural dan mudah diadopsi.

Perkembangan teknologi *Automatic Speech Recognition* (ASR) khususnya model Whisper dari OpenAI membuka peluang untuk mengotomasi proses ekstraksi informasi dari input suara. Namun, model Whisper belum dioptimalkan untuk domain perikanan dan kosakata spesifik inventori ikan, termasuk istilah lokal Makassar/Bugis seperti *samaleng*, *bulaeng*, *daeng*, dan *bosku*. Oleh karena itu, diperlukan proses *fine-tuning* agar model dapat mengenali istilah-istilah tersebut dengan akurasi yang lebih tinggi.

Proyek ini membangun sistem *Voice Extraction* berbasis Whisper yang di-*fine-tune* menggunakan dataset sintetis domain inventori ikan di Makassar, kemudian di-*deploy* sebagai API publik sehingga dapat diintegrasikan ke dalam sistem inventori digital.

2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam proyek ini adalah sebagai berikut:

- Bagaimana membangun dataset sintetis yang representatif untuk domain inventori ikan di Makassar?
- Bagaimana melakukan *fine-tuning* model Whisper agar mampu mengenali kosakata spesifik perikanan termasuk istilah lokal Makassar?
- Bagaimana membangun pipeline AI *end-to-end* dari pengumpulan data hingga *deployment*?
- Bagaimana men-*deploy* model ke *cloud* agar dapat diakses secara publik melalui API?

3 Tujuan Proyek

Berdasarkan rumusan masalah tersebut, tujuan dari proyek ini adalah sebagai berikut:

- Membangun dataset sintetis domain inventori ikan di Makassar sebanyak 2.799 sampel audio (2.499 training, 300 testing).
- Melakukan *fine-tuning* model Whisper Small pada dataset domain perikanan tersebut.
- Mengembangkan API berbasis FastAPI yang menerima input audio dan mengembalikan transkripsi.
- Men-*deploy* model ke HuggingFace Spaces sehingga dapat diakses melalui URL publik.

4 Batasan Masalah

Proyek ini dibatasi pada:

- Input audio dalam bahasa Indonesia dengan domain kosakata perikanan dan sapaan lokal Makassar/Bugis.
- Dataset sintetis yang dibuat menggunakan *text-to-speech* (gTTS) dan augmentasi audio (*audiomentations*).
- Model *base* yang digunakan adalah `openai/whisper-small`.
- *Training* dilakukan di platform Kaggle menggunakan GPU T4.
- *Deployment* menggunakan HuggingFace Spaces dengan kapasitas komputasi CPU.

5 Metodologi

5.1 Pengumpulan dan Persiapan Dataset

Dataset yang digunakan merupakan dataset sintetis yang dibuat khusus untuk domain inventori ikan di Makassar. Pembuatan dataset dilakukan secara programatik menggunakan pendekatan *template-based generation* yang dikombinasikan dengan *text-to-speech* (gTTS) dan augmentasi audio.

Kamus Lokal dan Template Kalimat Dataset dibangun dari kamus kata lokal yang mencakup komponen berikut:

- **Tindakan:** masuk, keluaran, ambil, simpan, tambah, catat

- **Nama ikan:** samaleng, bulaeng, jabiri, balang-balang, sunu, cakalang, tongkol, kerapu, udang, cumi-cumi, dan lainnya (58 jenis)
- **Grade:** grade a, grade b, grade c, super, biasa, rijek
- **Sapaan lokal:** daeng, iye, bos, bosku, pak
- **Satuan wadah:** kotak, boks, keranjang, gabus, ember, coolbox

Kalimat di-generate menggunakan 7 template yang merepresentasikan pola percakapan inventori ikan, contohnya:

- “{sapaan} {tindakan} {ikan} {berat} {grade} {waktu}”
- “{ikan} {berat} {grade} {sapaan}”
- “{waktu} ada {ikan} {grade} {wadah} {berat} {tindakan} {sapaan}”

Augmentasi Audio Setelah kalimat di-generate menjadi audio menggunakan gT-TS, setiap sampel diaugmentasi menggunakan library `audiomentations` untuk mensimulasikan kondisi nyata di pelabuhan Makassar. Augmentasi yang diterapkan meliputi:

Augmentasi	Probabilitas	Keterangan
AddBackgroundNoise	70%	Noise suara pelabuhan nyata
TimeStretch	50%	Variasi kecepatan bicara (0.8–1.25x)
PitchShift	50%	Variasi pita suara (± 4 semitone)
ClippingDistortion	20%	Simulasi suara pecah/teriak
LowPassFilter	30%	Simulasi mic tertutup tangan
AddGaussianNoise	30%	Simulasi sinyal statis/kresek
Gain	40%	Variasi volume (jauh/dekat)

Tabel 2: Teknik augmentasi audio yang diterapkan pada dataset

Pembagian Dataset Dataset dibagi menjadi dua bagian:

Split	Jumlah Audio
Training	2.499 audio
Testing	300 audio
Total	2.799 audio

Tabel 4: Pembagian dataset training dan testing

5.2 Arsitektur Model

Model yang digunakan adalah **Whisper Small** (`openai/whisper-small`) dengan 244 juta parameter. Whisper merupakan model *encoder-decoder* berbasis Transformer. *Encoder* memproses *mel spectrogram* dari sinyal audio, sedangkan *decoder* menghasilkan teks secara *autoregressive*.

Komponen	Detail
Base Model	openai/whisper-small
Jumlah Parameter	244 Juta
Input	Audio 16kHz Mono (Mel Spectrogram)
Output	Teks Transkripsi (Bahasa Indonesia)
Framework	HuggingFace Transformers + PyTorch
Training Platform	Kaggle (GPU T4)
Optimizer	AdamW
Learning Rate	1e-5
Batch Size	4 per device
Epochs	30
Task	Automatic Speech Recognition (Transcribe)

Tabel 6: Arsitektur dan konfigurasi model

5.3 Pipeline AI

Pipeline AI yang dibangun terdiri dari lima tahap utama:

No	Tahap	Proses	Output
1	Problem Definition	Mendefinisikan task ASR domain perikanan Makassar	Spesifikasi proyek
2	Data Preparation	Generate kalimat sintetis, TTS (gTTS), augmentasi audio	2.799 sampel audio
3	Fine-tuning	Seq2SeqTrainer, AdamW, 30 epoch, Kaggle GPU T4	Model .safetensors
4	Evaluation	WER & Akurasi pada 300 data test	Metrik performa
5	Deployment	FastAPI + Docker + HuggingFace Spaces	URL publik aktif

Tabel 8: Pipeline AI dari data preparation hingga deployment

5.4 Proses Fine-Tuning

Fine-tuning dilakukan menggunakan Seq2SeqTrainer dari HuggingFace Transformers pada platform Kaggle dengan GPU T4. Berikut kode utama fine-tuning yang digunakan:

Listing 1: Inisialisasi model dan processor Whisper

```
1 from transformers import WhisperProcessor,  
   WhisperForConditionalGeneration  
2  
3 model_id = "openai/whisper-small"  
4 processor = WhisperProcessor.from_pretrained(  
5     model_id, language="Indonesian", task="transcribe"  
6 )  
7 model = WhisperForConditionalGeneration.from_pretrained(model_id)
```

Listing 2: Argumen training Seq2SeqTrainer

```
1 training_args = Seq2SeqTrainingArguments(  
2     output_dir="./whisper-new-vision",  
3     per_device_train_batch_size=4,  
4     learning_rate=1e-5,  
5     num_train_epochs=30,  
6     fp16=True,  
7     predict_with_generate=True,  
8     generation_max_length=225,  
9 )
```

Proses training menunjukkan penurunan *training loss* yang konsisten dari 0.093570 pada step 500 hingga 0.000133 pada step 4500, yang mengindikasikan model berhasil mempelajari pola kosakata domain perikanan dengan baik.

Step	Training Loss
500	0.093570
1000	0.002674
1500	0.000925
2000	0.000494
2500	0.000771
3000	0.001364
3500	0.001542
4000	0.001452
4500	0.000133
5000	0.000621
5500	0.000231

Tabel 10: Perkembangan training loss selama proses fine-tuning

5.5 Deployment

Model di-deploy menggunakan FastAPI sebagai *framework* API dan Docker sebagai *container runtime*. *Container* di-host pada HuggingFace Spaces dengan *port* 7860. Model di-load langsung dari HuggingFace Hub (azharm1224/juku-version-2) saat *startup container*.

Listing 3: Endpoint POST /predict pada FastAPI

```

1 @app.post("/predict", response_model=TranscriptionResponse)
2 async def predict(file: UploadFile = File(...), language: str = "id
  "):
3     ext = os.path.splitext(file.filename)[-1].lower()
4     if ext not in {".wav", ".mp3", ".flac", ".ogg", ".m4a"}:
5         raise HTTPException(status_code=400, detail="Format_tidak_
          didukung")
6     with tempfile.NamedTemporaryFile(delete=False, suffix=ext) as
       tmp:
7         tmp.write(await file.read())
8         result = transcribe(tmp.name, language=language)
9     return TranscriptionResponse(
10         filename=file.filename,
11         language=language,
12         transcription=result
13     )

```


URL publik deployment: <https://azharm1224-voice-extraction-oti.hf.space>

6 Hasil dan Evaluasi

6.1 Hasil Training

Model berhasil di-*fine-tune* pada platform Kaggle dengan GPU T4 selama 30 epoch menggunakan 2.499 sampel audio training. Proses training menghasilkan model dengan format `.safetensors` berukuran 967 MB yang kemudian di-*upload* ke HuggingFace Hub (`azharm1224/juku-version-2`). Training loss menunjukkan konvergensi yang baik, turun dari 0.093570 menjadi 0.000133.

6.2 Hasil Evaluasi Model

Evaluasi dilakukan pada 300 sampel audio testing. Sama seperti data training, data testing juga diaugmentasi dengan noise pelabuhan untuk mensimulasikan kondisi nyata di lapangan.

Metrik	Nilai	Keterangan
Total Data Test	300 audio	Dataset terpisah dari training yang digunakan untuk evaluasi
Word Error Rate (WER)	0.20%	Semakin rendah semakin baik
Akurasi Model	99.80%	Semakin tinggi semakin baik

Tabel 12: Hasil evaluasi model pada data testing

Nilai WER sebesar 0.20% menunjukkan bahwa model sangat mampu men-transkripsikan kosakata domain inventori ikan, termasuk istilah lokal Makassar/Bugis, dengan tingkat kesalahan yang sangat rendah. Namun, ini mengindikasikan adanya overfitting.

6.3 Hasil Inferensi

Berikut contoh hasil inferensi model pada data uji:

Input Audio	Hasil Transkripsi
test1.mp3	masuk ikan sunu grade a dua puluh lima kilo

Tabel 14: Contoh hasil inferensi model pada data uji

6.4 Hasil Deployment

Item	Detail
URL Publik	https://azharm1224-voice-extraction-oti.hf.space
Endpoint	POST /predict
Platform	HuggingFace Spaces (Docker)
Status	Running
Input	File audio (WAV, MP3, FLAC, OGG, M4A)
Output	JSON {filename, language, transcription}

Tabel 16: Informasi deployment model

Contoh respons JSON endpoint /predict:

Listing 4: Contoh respons JSON endpoint /predict

```

1 {
2   "filename": "test1.mp3",
3   "language": "id",
4   "transcription": "masuk_ikan_sunu_grade_a_dua_puluh_lima_kilo"
5 }
```

6.5 Kelebihan dan Keterbatasan Sistem

Sistem yang dibangun memiliki beberapa kelebihan. Pertama, model dapat diakses secara publik melalui URL tanpa perlu instalasi. Kedua, API mendukung berbagai format audio (WAV, MP3, FLAC, OGG, M4A). Ketiga, augmentasi noise pelabuhan pada data training membuat model lebih *robust* terhadap kondisi akustik yang tidak ideal.

Di sisi lain, sistem masih memiliki beberapa keterbatasan yang perlu diperhatikan:

- **Indikasi overfitting:** Nilai WER yang sangat rendah (0.20%) dan *training loss* yang turun hingga 0.000133 mengindikasikan adanya *overfitting*. Hal ini terjadi karena dataset *training* dan *testing* dibuat dari template dan kamus kata yang sama, sehingga model sangat mengenali pola data sintesis tersebut namun belum tentu dapat menggeneralisasi dengan baik pada suara nyata di lapangan.
- **Dataset sintesis:** Suara yang dihasilkan gTTS memiliki karakteristik yang seragam dan tidak merepresentasikan variasi intonasi, aksen, serta gaya bicara asli nelayan Makassar.

- **Performa CPU:** Model berjalan di CPU sehingga *response time* relatif lebih lambat (3–5 detik per *request*).
- **Kosakata terbatas:** Model hanya mengenali nama ikan dan istilah yang telah didefinisikan dalam kamus data training.

7 Kesimpulan dan Saran

7.1 Kesimpulan

Proyek ini berhasil membangun dan men-*deploy* sistem *Voice Extraction* berbasis Whisper *fine-tuned* untuk domain inventori ikan di Makassar. Hasil yang dicapai:

- Dataset sintetis domain perikanan berhasil dibangun sebanyak 2.799 sampel audio (2.499 training, 300 testing) menggunakan pendekatan *template-based generation* + gTTS + augmentasi noise pelabuhan.
- Model Whisper Small berhasil di-*fine-tune* dengan *training loss* yang konvergen hingga 0.000133 setelah 30 epoch.
- Model mencapai akurasi 99.80% (WER 0.20%) pada 300 data test.
- API FastAPI berhasil di-*deploy* ke HuggingFace Spaces dengan URL publik yang aktif dan dapat diuji melalui Postman.

7.2 Saran

Beberapa hal yang dapat dikembangkan ke depannya:

- Memperluas dataset dengan rekaman suara nyata dari nelayan di pelabuhan Makassar untuk meningkatkan *robustness* terhadap aksen lokal yang sesungguhnya.
- Mengintegrasikan model dengan sistem inventori berbasis *database* agar hasil transkripsi dapat langsung disimpan secara otomatis.
- Menambahkan *post-processing* NLP untuk mengekstrak entitas terstruktur (nama ikan, *grade*, kuantitas) dari hasil transkripsi.
- Mencoba *base model* yang lebih besar seperti *whisper-medium* untuk meningkatkan akurasi lebih lanjut.
- Menjalankan model di GPU untuk mengurangi *response time* API.